

Relatório de Laboratório

Laboratório de Experimentação de Software

Link do Site: <https://arsenal.dev.br/lab02/#dashboard>

Curso	Engenharia de Software
Disciplina	Laboratório de Experimentação de Software
Turno / Período	Noite / 6º
Professor(a)	Danilo Maia
Laboratório	Lab02 - Assistentes de IA vs. Codificação Manual
Grupo (trio)	Isabella Dias · Leandro Alencar · Luis Henrique
Link do repositório / GitHub Projects	https://github.com/IsabellaLDias/assistente-ia-vs-codificacao-manual
Data de entrega	24/09/2026

1. Introdução

Assistentes de IA podem produzir soluções rapidamente, mas essa rapidez não garante correte nem facilidade de manutenção. Neste laboratório, comparamos registros de resolução de katas em Java com e sem assistência do Gemini. O objetivo é avaliar produtividade e características do código, sem confundir uma diferença observada em uma amostra pequena com evidência generalizável de superioridade.

O estudo segue o objetivo GQM do enunciado: analisar o uso de IA na programação, do ponto de vista do grupo, quanto a tempo, qualidade funcional e estrutura do código. Às três questões originais, acrescentamos uma quarta, sobre eficiência de execução:

RQ1. O uso de assistente de IA reduz o tempo necessário para resolver uma tarefa de programação?

RQ2. O uso de assistente de IA reduz a quantidade de defeitos, medida pelos testes de aceitação que falham?

RQ3. O uso de assistente de IA altera a complexidade ciclomática ou a duplicação do código produzido?

RQ4. O código produzido com IA difere do manual em latência de execução e alocação de memória?
Esta questão adicional foi proposta pelo grupo e aparece no dashboard.

Para RQ1, a hipótese alternativa é uma redução de tempo com IA. Para RQ2, o desenho registrado usa uma alternativa bilateral para a taxa de aprovação; uma melhora nessa taxa corresponderia a menos falhas. Para o RQ3, o desenho prevê diferenças bilaterais de complexidade e duplicação.

Operacionalizamos H_0 no Wilcoxon como a simetria da distribuição das diferenças pareadas em torno de zero, sob as condições do teste.

2. Contexto

A escolha de regras de negócio específicas procura reduzir a reutilização de soluções clássicas memorizadas pela IA, mas não elimina esse risco. Cada kata possui oito casos de aceitação. A proximidade temática favorece a comparação, sem constituir uma calibração empírica de dificuldade equivalente.

ID	Kata	Objeto principal
K1	Estacionamento Rotativo	Permanência, franquia, tarifas e descontos
K2	Logística Urbana	Frete, distância, peso e modalidades
K3	Hospedagem e Pousada	Diárias, categorias e regras de hospedagem
K4	Plano de Saúde	Mensalidade e regras de contratação

O projeto contém um desenho crossover, mas a distribuição efetivamente registrada não é inteiramente balanceada; essa diferença é tratada na metodologia e nos resultados.

3. Metodologia

3.1 Principais Desafios

O principal desafio foi manter comparáveis os tratamentos diante de quantidades diferentes de registros e de revisões posteriores do código. A base reúne 16 trials: nove COM IA e sete SEM IA. Isabella possui

dois por condição; Leandro, três com IA e um sem; Luis, quatro por condição. Portanto, os 16 registros não formam oito pares independentes do mesmo participante e kata.

Outro desafio foi distinguir instrumentos previstos de medidas efetivamente disponíveis. A infraestrutura prevê CK e PMD, mas a série estrutural atualmente consolidada no dashboard deriva da extração dos PDFs e expressões regulares. Também há diferença entre observar testes aprovados numa reexecução e comprovar o instante em que o código passou nos testes durante a sessão original.

3.2 Tomadas de Decisão

COM IA representa o uso do Gemini; SEM IA corresponde à programação manual. A linguagem das soluções é Java e o limite previsto é de 35 minutos.

Para incluir os três integrantes sem tratar repetições como observações independentes, utilizamos a mediana dos tempos de cada participante em cada condição. O Wilcoxon de RQ1 compara três pares de medianas. Essa agregação controla parcialmente as diferenças individuais, mas não equilibra os katas nem substitui o contrabalanceamento planejado.

Mantivemos o Wilcoxon signed-rank exato do script do grupo, com diferença COM IA menos SEM IA e nível de significância de 5%. RQ1 usa alternativa unilateral à esquerda. RQ2 usa alternativa bilateral sobre a taxa de aprovação. Diferenças nulas não recebem postos; se todas forem nulas, o teste não é calculado. Não substituímos esse caso por um valor arbitrário.

Não imputamos observações nem removemos tempos extremos para melhorar resultados. Um trial censurado deveria permanecer registrado em 35 minutos.


3.3 Etapas

A divisão de atividades abaixo acompanha as responsabilidades das issues do repositório. S01, S02 e S03 correspondem às etapas do enunciado.

Etapa	Entregas e responsáveis	Issues
S01	Isabella: cronômetro. Leandro: ambiente e métricas. Luis: katas e desenho. Revisão conjunta.	#1–4
S02	Trials de Isabella, Leandro e Luis; complementação dos katas por Luis.	#5–8
S03	Leandro: Wilcoxon RQ1/RQ2. Isabella: RQ3. Luis: dashboard.	#9–11
Relatório	Consolidação e revisão pelos três integrantes.	#12

Configuração do processo

O fluxo do quadro é Backlog → Ready → In progress → In review → Done. Os limites configurados são cinco itens em Backlog, três em In progress e cinco em In review; Ready e Done não exibem limite. O teto de três atividades em execução é compatível com uma atividade principal por integrante.



3.4 Ferramentas

A aplicação reúne cronômetro, registro de resultados, anexos de código ou texto e exportação de relatórios. O servidor Node.js 20 ou superior utiliza PostgreSQL para persistência; o pacote web está na versão 1.0.0. As soluções são Java e a validação funcional usa JUnit 5. O tratamento assistido utiliza Gemini.

3.5 Tabela de Métricas

RQ	Métrica	Definição Operacional	Unidade	Ferramenta / Fonte
RQ1	Tempo	Mediana dos segundos registrados por participante e tratamento; diferença COM - SEM.	s	Cronômetro e análise pareada
RQ2	Taxa de aprovação	$100 \times \text{testes aprovados} / \text{testes executados}$ na revalidação de 20/09.	%	JUnit 5 e análise RQ1/RQ2
RQ2	Testes falhos	Testes executados menos aprovados, por trial.	casos	Mesma revalidação
RQ3	LOC aproximado	Linhas não vazias e não comentadas na classe Tarifador extraída do PDF.	linhas	Parser de contingência
RQ3	WMC aproximado	Contagem de assinaturas de métodos e marcadores de decisão, por expressões regulares.	contagem	Parser de contingência

3.6 Inovações Propostas pelo Grupo (30% da nota)

A contribuição de infraestrutura é integrar coleta, banco de dados, código anexado, PDF e dashboard numa única aplicação. Isso facilita relacionar cada resultado ao seu artefato e permitiu conferir as revisões de código antes da análise. A contribuição analítica complementar é explicitar os três níveis de evidência: trial, participante e versão de código.

A RQ4 amplia o estudo para latência de execução e alocação de memória. O dashboard já implementa bullet graphs para essa questão. Incluímos essa visualização e seus valores configurados na seção de resultados, distinguindo a implementação do painel da validação empírica de uma diferença entre tratamentos.

4. Resultados

4.1 Coleta de Dados

O recorte reúne 16 registros e suas classes de solução: quatro de Isabella, quatro de Leandro e oito de Luis. O tratamento com IA contém nove registros, contra sete manuais.

Participante	SEM IA	COM IA	Total
Isabella	2	2	4
Leandro	1	3	4
Luis	4	4	8
Total	7	9	16

Os tempos registrados variam de 19 a 74 segundos com IA e de 1.130 a 1.974 segundos sem IA. Todos estão abaixo de 35 minutos. Mantivemos os valores extremos porque não há critério prévio documentado que justifique removê-los.

Medida descritiva	SEM IA	COM IA
Tempo por trial · mediana [Q1; Q3]	1.425 [1.303; 1.631] s	58 [48; 63] s
IQR do tempo por trial	328 s	15 s
Testes aprovados / executados	56 / 56	72 / 72
LOC aproximado · mediana [Q1; Q3]	87 [67,5; 93,5]	43 [39; 47]
WMC aproximado · mediana [Q1; Q3]	17 [16; 18,5]	10 [10; 10]

Tabela descritiva dos 16 trials, com agrupamentos de tamanhos diferentes. Estes valores não são as três medianas pareadas utilizadas no Wilcoxon. Fonte: dashboard e resultados do grupo.

Cada kata possui oito testes automatizados que verificam se o código calcula os valores esperados e rejeita entradas inválidas:

- **Estacionamento:** verifica a gratuidade inicial, a cobrança pelo tempo de permanência, os ajustes por veículo e os descontos.
- **Logística:** confere o frete conforme distância e peso, além dos adicionais de entrega expressa e carga frágil.
- **Hospedagem:** verifica o preço conforme número de diárias, hóspedes, categoria do quarto, limpeza e convênio.
- **Plano de Saúde:** confere a mensalidade conforme idade, categoria, acomodação, cobertura odontológica e coparticipação.

Os oito testes de cada kata foram aplicados às respectivas soluções com e sem IA. Nas 16 soluções analisadas, isso totalizou 128 execuções, todas aprovadas na revalidação. Esse resultado indica que os códigos atenderam aos cenários verificados.

4.2 Visualização Gráfica

RQ1 - Tempo de resolução

O uso de assistente de IA reduz o tempo necessário para resolver uma tarefa de programação?




Figura 2. Slopegraph pareado do dashboard. Roxo: Isabella; azul: Leandro; verde: Luis. Rótulos de tempo exibem segundos inteiros como na interface; a tabela mantém as frações usadas no cálculo. Fonte: dashboard do grupo.

O slopegraph conecta a condição manual à assistida de cada participante. A inclinação descendente indica menor tempo registrado com IA; as duas colunas usam a mesma escala em minutos. Com apenas três pares, o gráfico mostra toda a amostra de inferência. Os rótulos foram espaçados para evitar sobreposição, sem mover os pontos ou alterar as trajetórias.

Participante	SEM IA	COM IA	Diferença COM - SEM
Isabella	1.853 s	38,5 s	-1.814,5 s
Leandro	1.366 s	58 s	-1.308 s
Luis	1.332,5 s	58,5 s	-1.274 s

A mediana das três medianas caiu de 1.366 s para 58 s, diferença de 1.308 s e redução descritiva de 95,8%. O Wilcoxon apresentou $W^+ = 0$, $W^- = 6$ e p unilateral exato = 0,125; a referência bilateral é 0,25. Como $0,125 > 0,05$, não rejeitamos H_0 .

Todos os sinais favorecem menor tempo com IA, produzindo correlação rank-biserial de -1. Esse extremo descreve a consistência dos três pares, não a precisão de uma estimativa populacional. Com três diferenças não nulas, o menor p unilateral possível neste teste exato é $1/8$; a amostra não consegue alcançar 5%, mesmo quando todos os pares têm a mesma direção.

Postos sinalizados de Wilcoxon

Como as diferenças individuais de tempo contribuem para o resultado do Wilcoxon?




Figura 3. Waterfall divergente do dashboard. O comprimento das barras representa a diferença de tempo, enquanto o texto identifica o posto atribuído. O zero é uma referência de diferença nula, não um limiar de significância. Fonte: dashboard do grupo.

Ordenamos os valores absolutos das diferenças COM IA – SEM IA. Luis recebe posto 1 para 1.274 s; Leandro, posto 2 para 1.308 s; Isabella, posto 3 para 1.814,5 s.

RQ2 Testes de aceitação

O uso de assistente de IA reduz a quantidade de defeitos observados nos testes de aceitação?

RQ2 · Aprovação nos testes de aceitação

Revalidação de 16 snapshots em 20/09/2026

	SEM IA	COM IA
Isabella	100% 16/16 testes	100% 16/16 testes
Leandro	100% 8/8 testes	100% 24/24 testes
Luis	100% 32/32 testes	100% 32/32 testes
	Total: 56/56	Total: 72/72

Diferenças pareadas = 0: não há postos não nulos para o Wilcoxon.

Figura 4. Taxas de aprovação e contagens por participante e tratamento. Revalidação de 20/09/2026: 56/56 casos sem IA e 72/72 com IA. Fonte: resultados RQ1/RQ2; elaboração do grupo.

Os 16 trials passaram nos oito casos de aceitação respectivos, totalizando 128/128 aprovações e zero falhas observadas nessa revalidação. Isabella obteve 16/16 em cada condição; Leandro, 8/8 sem IA e 24/24 com IA; Luis, 32/32 em cada condição.

As suítes delimitam a evidência: aprovação completa não prova ausência de falhas fora dos cenários cobertos.

RQ3 Estrutura do código

O uso de assistente de IA altera a complexidade ciclomática ou a duplicação do código produzido?




Figura 5. Dispersão em quadrantes do dashboard. Azul: COM IA; laranja: SEM IA.

As diagonais indicam WMC/LOC de 0,10, 0,20 e 0,25; o raio dos pontos cresce com o tempo registrado. O eixo WMC mantém o rótulo original, mas representa uma aproximação por parser, não medição CK. Fonte: dashboard.

As medianas são 43 LOC e WMC aproximado 10 com IA, contra 87 LOC e WMC aproximado 17 sem IA. O dashboard divide os quadrantes em LOC = 47 e WMC = 11, valores fixados no código da visualização. Esses cortes organizam o painel; não constituem limiares validados de risco. As expressões “Zona Ideal” e “Hotspots” são rótulos visuais, não demonstrações de qualidade ou manutenibilidade.

O parser soma assinaturas de métodos e ocorrências de if, for, while, case, catch, ?, && e | |. Sem análise sintática Java, essa contagem pode incluir ou perder elementos e não representa a média McCabe por método. A extração de uma única classe Tarifador por PDF também deixa de fora enums e testes; quebras de linha no PDF podem afetar o LOC.

Os valores de duplicação iguais a zero no dashboard não correspondem a execução comprovada do CPD para essa série. Por isso, não os interpretamos como “nenhuma duplicação”. Medições nativas antigas de CK/CPD pertencem a versões anteriores e não foram misturadas com os códigos revisados. RQ3 permanece parcialmente respondida em caráter exploratório, sem conclusão confirmatória sobre complexidade ou duplicação.

RQ4 Eficiência de execução

O código produzido com IA difere do manual em latência de execução e alocação de memória?




Figura 6. Bullet graphs de eficiência de execução do dashboard. Barras escuras: valores configurados por kata; linha vermelha: referência de 0,094 µs. As faixas verdes e cinza reproduzem a classificação visual do painel, sem representar padrões validados de desempenho. Fonte: dashboard e seu gerador de dados.

A RQ4 foi definida no desenho experimental como extensão do grupo. Suas hipóteses alternativas preveem diferenças bilaterais de latência de execução e de alocação de memória entre COM IA e SEM IA. A latência pretendida é tempo por cálculo em microssegundos, após aquecimento da JVM; a alocação pretendida é bytes por operação. Nenhuma delas deve ser confundida com o tempo de desenvolvimento da RQ1.

Kata	Latência no painel	Heap no painel
K1 · Estacionamento	0,082 μ s	32 B
K2 · Logística	0,095 μ s	48 B
K3 · Hospedagem	0,088 μ s	40 B
K4 · Plano de Saúde	0,110 μ s	56 B

4.3 Discussão

RQ1 - Tempo: Os três participantes registraram tempos menores com IA, mas a diferença não foi estatisticamente significativa a 5%. A amostra pequena e a forma de cronometrar limitam a conclusão.

RQ2 - Testes: Todas as soluções passaram nos testes da revalidação.

RQ3 - Estrutura do código: Ao comparar apenas o método solicitado em cada kata, a mediana com IA foi maior: 32 linhas e WMC 10, contra 12 linhas e WMC 2 sem IA. O CK mediu esses valores diretamente. Como algumas soluções manuais distribuem a lógica em métodos auxiliares. O PMD CPD não encontrou duplicação relevante dentro de cada solução.

RQ4 - Eficiência: O benchmark mediu latência e alocação de memória em 16 soluções completas, as diferenças de latência entre com e sem IA foram pequenas e não seguiram a mesma direção em todos os casos; a alocação de memória foi praticamente igual.

5. Conclusão

O uso do Gemini esteve associado ao menor tempo registrado, mas também a mais linhas e maior complexidade na métrica estrutural adotada. Assim, a rapidez observada não veio acompanhada de código mais enxuto nessa análise. Todas as soluções passaram nos testes de revalidação, sem diferença funcional observada entre os tratamentos. O benchmark também não indicou vantagem consistente de latência ou memória.

Em conjunto, os resultados sugerem que a IA pode acelerar a produção de soluções que atendem aos testes, enquanto a simplicidade e a eficiência dependem das escolhas de implementação. O estudo contou com uma distribuição equilibrada entre as condições com e sem IA. Os resultados descrevem a experiência durante o período de coleta e oferecem uma base para novas comparações.

Com mais tempo, poderia ocorrer a ampliação do número de participantes e repetições, além de automatizar o registro do tempo, das versões do código e dos resultados dos testes. A integração entre coleta e dashboard merece ser expandida para facilitar o acompanhamento das tarefas e aprofundar a análise dos efeitos da IA no desenvolvimento de software.

5. Referências

- MAIA, Danilo. LAB02: Assistentes de IA vs. codificação manual: um experimento controlado. Enunciado da disciplina Laboratório de Experimentação de Software, 2026.
- SANTOS, Isabella Luiza Dias dos; CLEMENTE, Leandro Alencar Pereira; BARBOSA, Luis Henrique Gonçalves. Repositório do LAB02. Código, desenho experimental, katas, resultados e dashboard. Consulta em 23 set. 2026.
<https://github.com/IsabellaLDias/assistente-ia-vs-codificacao-manual>
- GRUPO LAB02. Artefatos de análise: dados pareados e resultado Wilcoxon; métricas por classe; consolidação dashboard-data.json, identificada como 22 set. 2026 no campo de data do arquivo. Artefatos versionados no repositório.
- SCIPY. `scipy.stats.wilcoxon`. Documentação do teste de postos sinalizados, hipóteses e tratamento de diferenças nulas. Referência conceitual; o cálculo utilizado é implementado no script do grupo. Consulta em 23 set. 2026.
<https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.wilcoxon.html>
- ANICHE, Mauricio et al. CK: code metrics for Java code. Documentação e implementação da ferramenta de métricas estáticas. Consulta em 19 set. 2026.
<https://github.com/mauricioaniche/ck>
- GRUPO 1. Análise de Dados Aplicada à Experimentação em Engenharia de Software. Material didático, PUC Minas, 2025. Arquivo `trab-final-pdf.pdf`, especialmente as páginas 45, 49 e 95, sobre dispersão, mapas de calor e escolha de gráficos.
- GRUPO LAB02. Lab 02 - Experimentação de Software. Quadro público GitHub Projects, número 4. Estado consultado em 22 set. 2026.
<https://github.com/users/IsabellaLDias/projects/4>